Proyecto del curso

Machine Learning y Deep Learning Aplicados

Marcelo Jafett Contreras Cabrera
mcontreras@utec.edu.pe

22 de septiembre de 2026

Índice

1. Introducción **2**

2. Dataset **2**
2.1. Tarea 1: Food-101 . . . 2
2.2. Tarea 2: AG News . . . 2

3. Descripción del Problema **2**
3.1. Definición del problema . . . 2

4. Metodología **3**

5. Plan Experimental **3**
5.1. Preprocesamiento de datos . . . 3
5.2. Entrenamiento y validación . . . 3
5.3. Métricas . . . 4
5.4. Convergencia . . . 4
5.5. Interpretabilidad . . . 4

6. Entregables **4**
6.1. Reporte . . . 4
6.1.1. Uso de herramientas de IA generativa . . . 5
6.2. Código . . . 5

1. Introducción

El objetivo principal de este proyecto es desarrollar y evaluar un modelo clasificador capaz de:

- Demostrar dominio de los métodos de Machine Learning y Deep Learning estudiados a lo largo del curso.
- Explicar y justificar las decisiones de diseño del clasificador con base en fundamentos teóricos y consideraciones prácticas.
- Comparar dos métodos, no solo con base en métricas de desempeño, sino también considerando propiedades de los clasificadores (por ejemplo, interpretabilidad, complejidad y costo computacional), y justificar cuál resulta más adecuado para la tarea asignada.

Cada grupo tendrá asignada una de las dos tareas de clasificación y deberá entregar tanto un reporte formal como una base de código que permita explicar y reproducir los resultados obtenidos.

2. Dataset

2.1. Tarea 1: Food-101

- Clasificación de imágenes.
- Número de clases: 101.
- Número de muestras: 101000.
- Dimensionalidad de las entradas: variable; las imágenes presentan distintas resoluciones y deberán ser preprocesadas de acuerdo con los requerimientos del modelo.
- Descarga: HuggingFace

2.2. Tarea 2: AG News

- Clasificación de textos.
- Número de clases: 4.
- Número de muestras: 127600.
- Dimensionalidad de las entradas: Variable.
- Descarga: HuggingFace

3. Descripción del Problema

3.1. Definición del problema

Formalmente, se desea aprender una función

$$f_\theta : \mathcal{X} \to \mathcal{Y}, \tag{1}$$

donde $\mathcal{X}$ representa el espacio de entrada, $\mathcal{Y}$ representa el espacio de salida compuesto por las etiquetas de clase, $\mathcal{Y} = \{1, \ldots, K\}$. El clasificador, ya sea paramétrico o no paramétrico, debe ser entrenado para minimizar el error de clasificación a partir de un conjunto de entrenamiento

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^{N}, \tag{2}$$

En el caso de un modelo paramétrico (por ejemplo, una red neuronal o una SVM), el objetivo es encontrar

$$\theta^* = \arg\min_{\theta} \frac{1}{N} \sum_{i=1}^{N} \mathcal{L}\left(f_\theta(\mathbf{x}_i), y_i\right), \tag{3}$$

donde $\mathcal{L}$ corresponde a la función de pérdida. Dado que las tareas corresponden a problemas de clasificación multiclase, para modelos que produzcan probabilidades por clase se recomienda utilizar la pérdida de entropía cruzada (*cross-entropy loss*):

$$\mathcal{L}_{\text{CE}} = -\frac{1}{N} \sum_{i=1}^{N} \sum_{c=1}^{C} y_{i,c} \log\left(\hat{y}_{i,c}\right), \tag{4}$$

donde $y_{i,c}$ es el indicador de que la muestra i pertenece a la clase c y $\hat{y}_{i,c}$ es la probabilidad predicha para dicha clase. No obstante, se podrán utilizar otras funciones de pérdida cuando exista una justificación metodológica. Por ejemplo, ante un desbalance de clases pueden considerarse variantes ponderadas de la entropía cruzada o *focal loss*.

4. Metodología

Se deberán seleccionar al menos dos algoritmos de clasificación. La elección es libre: podrán utilizarse tanto los métodos estudiados en clase como métodos más avanzados. Para cada algoritmo se deberá:

- Definir el espacio de hipótesis.
- Definir un objetivo de optimización y el algoritmo de entrenamiento.
- Especificar el modelo matemático del clasificador.
- Explicar las principales consideraciones y supuestos del modelo (por ejemplo, separabilidad de clases, balance de los datos, correlación entre variables, regularización, entre otros).

5. Plan Experimental

5.1. Preprocesamiento de datos

El escalamiento, la normalización, el centrado, la decorrelación y las transformaciones específicas del dominio son algunas de las técnicas que pueden considerarse. Todo procedimiento de preprocesamiento utilizado deberá describirse y justificarse para la tarea asignada.

5.2. Entrenamiento y validación

- Proponer una separación apropiada de los datos en conjuntos de entrenamiento, validación y prueba, o utilizar validación cruzada (*cross-validation*) cuando corresponda.
- Describir el procedimiento utilizado para la selección de hiperparámetros.
- Garantizar, en la medida de lo posible, la reproducibilidad de los experimentos, incluyendo el uso de semillas para los procesos aleatorios y el registro de las configuraciones empleadas.

5.3. Métricas

Los clasificadores deberán evaluarse y compararse mediante *accuracy*, *precision*, *recall* y *F1-score*. Asimismo, se deberá incluir una matriz de confusión cuando esta contribuya al análisis de los errores del modelo.

5.4. Convergencia

Para los modelos entrenados de manera iterativa, se deberán presentar las curvas de la función de pérdida para entrenamiento y validación. Se deberá discutir si el ajuste obtenido es adecuado, identificando posibles casos de *underfitting* u *overfitting*. También deberá analizarse la estabilidad de las curvas (por ejemplo, la presencia de oscilaciones o ruido) y relacionarla con la arquitectura del modelo, el algoritmo de optimización y los hiperparámetros seleccionados.

5.5. Interpretabilidad

Se debe incluir algun metodo de interpretabilidad de la representacion aprendida en caso que el metodo no sea explicable por si mismo, e.g. redes neuronales. Se recomienda utilizar algun algoritmo de reducción de dimensionalidad como PCA, UMAP o t-SNE. Se espera un análisis cualitativo de la estructura de la representación, identificando posibles agrupamientos, clases solapadas, outliers o patrones relevantes.

6. Entregables

6.1. Reporte

La metodología propuesta, los hallazgos experimentales y la discusión de los resultados deberán presentarse en un informe escrito con una extensión máxima de 12 páginas. Este límite incluye la lista de referencias y los anexos, en caso de ser necesarios. Se utilizará como referencia la plantilla de conferencia de IEEE. El reporte deberá incluir, como mínimo, las siguientes secciones:

- **Resumen o abstract**: Presenta brevemente el problema abordado, los métodos utilizados y los principales resultados obtenidos.
- **Introducción**: Presenta la relevancia del problema, describe brevemente los métodos utilizados y contextualiza el trabajo con respecto al estado del arte.
- **Metodología**: Explica los métodos utilizados para resolver el problema de clasificación y justifica su elección frente a otras alternativas. Deberán incluirse los pasos necesarios para reproducir el trabajo, incluyendo los fundamentos matemáticos relevantes, el preprocesamiento de los datos y el diseño de los clasificadores.
- **Experimentos**: Describe el conjunto de datos, las métricas utilizadas, el protocolo de entrenamiento y validación (*split*, *cross-validation*, etc.), los hiperparámetros relevantes y el hardware empleado.
- **Resultados y discusión**: Reporta los resultados de clasificación mediante las métricas definidas y presenta una comparación entre los dos métodos seleccionados. Además, deberá incluirse un estudio de ablación o un análisis controlado de hiperparámetros que permita justificar decisiones relevantes, como el optimizador, el tamaño o complejidad del modelo (cuando corresponda), el tamaño de lote (*batch size*) u otros hiperparámetros. La discusión deberá interpretar los resultados, proponer explicaciones sustentadas para el rendimiento observado, analizar los errores y señalar las principales limitaciones del trabajo.

- **Conclusiones**: Resume los principales hallazgos, incluyendo resultados cuantitativos relevantes, y propone posibles líneas de trabajo futuro.

6.1.1. Uso de herramientas de IA generativa

En caso de utilizar herramientas de IA generativa (por ejemplo, ChatGPT o Claude) durante la elaboración del reporte, su uso deberá declararse explícitamente en una sección adicional de *Reconocimientos* (*Acknowledgements*) al final del documento. Su uso se restringe a la elaboración de diagramas metodológicos o resúmenes gráficos y a la corrección gramatical o de estilo del texto. El contenido técnico, el análisis, la interpretación de los resultados y la redacción original deberán ser responsabilidad de los estudiantes. Esta restricción no impide el uso de modelos preentrenados, como BERT u otros modelos de Deep Learning, cuando formen parte de la metodología experimental del proyecto.

6.2. Código

Con el objetivo de garantizar la transparencia y reproducibilidad de los resultados, se deberán compartir los scripts y el código utilizados durante el proyecto. La elección del lenguaje de programación (C++, Python, MATLAB, Julia o R) es libre. Los archivos deberán entregarse en un archivo `.zip` que incluya instrucciones claras para reproducir los resultados del reporte, preferentemente mediante un archivo `README.md`. También deberán indicarse las dependencias y versiones relevantes del entorno de ejecución.